

Bias / Variance - Trade Off

$$\text{Error} = \text{Bias}^2 + \text{Var} + \text{Noise}$$

	Bias	Variance
Что?	насколько модель в среднем упрощается	насколько перег. модели на разн. Train
Вопрос	Underfitting	Overfitting
Тип модели	Простые (linear)	Сложные (deep tree)
Как решить	Усложнить модель, добавить фичи	Результаты, данные упростить, добавить

Вопрос баланса между Bias и Var

	<u>Underfitting</u>	<u>Overfitting</u>
Train Score	высокий	низкий
Val Score	высокий	высокий
Причина	модель слишком упрощена	модель слишком сложна или переобучена
Fix	Усложнить, добавить фичи, уменьшить регуляризацию	Упростить, данные упростить, regularization, early stopping

Cross Validation

Method	Когда	Особенности
K-Fold	оду или много	$K=5$ или $K=10$
K-Fold Stratified	Несбалансированные классы	Сохранять долю классов в каждом фолде
Group K-Fold	Есть группы (один элемент в несколько строк)	Не смешивает группы между фолдами
Time Series Split	Временные ряды	Только вперед по времени

CV нужен train, validation для параметров,
test - отдельно

Data Leakage

Тип	Что происходит	Пример
Target Leakage	Фича коррелирует с таргетом и ее присутствие в inference	"Прочел ли курс лекции" для студента в заголовке
Target-test Leakage	Preprocessing на всем датасете до splits	Scaling на train + val вместе
Temporal Leakage	Будущее попадает в прошлое	Усреднение по всему периоду, когда смотрят во времени

Правила

- 1) Сплит до preprocessing
- 2) Никаких агрегаций, которые используют train/val
- 3) Использовать Pipeline

Feature Engineering

Method	Когда	Применение
One-hot	мало категорий	Бинарные, не требуют и мультиколлинеарности
Ordinal	Есть порядок	Образование, рейтинг
Target Encoding	Много категорий	Риск leakage → только внутри CV
Frequency Encoding	Бояро, когда порядок не важен	Заменяет категорию на частоту
Cat Boost native	Cat Boost	cat_features

Scaler

Method	Зачем
Standard Scaler	mean=0, std=1 - для линейных, SVM, NN
MinMax Scaler	[0,1] - для NN, корректно форму
Robust Scaler	медиана + IQR - устойчив к выбросам

Фильтр и охват

Filter - корреляция, mutual information,
 χ^2 - тоже можно

Wrapper - RFE, forward/backward selection
также можно

Embedded - L1 (Lasso), feature importance в
seplib ex

Regularization

L2 (Ridge) - уменьшает веса, но не
закрепляет

L1 (Lasso) - закрепление веса (один
и охват)

Elastic Net - Компромисс между L1 и L2,
когда они коррелируют

Early stopping - Остановка, когда val падает

Max depth - Ограничение глубины дерева

Анализ

Linear Regression

$$\hat{y} = wx + b$$

$$\text{Loss: MSE } \sum (y - \hat{y})^2$$

Анализировать рефз МНК: $W = (X^T X)^{-1} X^T y$
увеличить к масштабу фич, чтобы коэффициенты были близкими

Результаты: L2, L1, Elastic net

Logistic Regression

$$P(y=1) = \frac{1}{1 + e^{-(wx+b)}}$$

Loss: log-loss (binary cross-entropy)

Гранича решение: непрерывность (линейная)

Результаты: L1 (разрешение), L2 (стабильность)

Вероятности: калибровка модели, чем у деревьев

Decision Tree

Разбирается по порогу $gain \rightarrow \max$ information
 $gain / \min$ $gain /$
 $\min$ MSE

Плюсы: интерпретируем, работает с категори.,
не требует scaling

Минусы: плохо переносит шум, не масштабируется
(малое изменение данных $\rightarrow$ другой результат)

Ключ. гиперпарам.: $\max\text{-depth}$, $\min\text{-samples_leaf}$,
 $\min\text{-samples_split}$, $\max\text{-features}$

Random Forest

Базируются: обучают N деревьев на bootstrap-
выборках, усредняют

Уменьшается variance, bias почти не меняется

$\max\text{-features} = 'sqrt'$ - стандарт для сортировки

Важнейшая фича - feature importance

Плюсы: минимальный tuning, OOB score как втр. валидация

Минусы: избыточность, сложно объяснить

Gradient Boosting

Почему важно: чтобы было и славно и красиво
и быстро и просто

меньше bias, variance не меньше

Ансамбль слабых моделей $\rightarrow$ сильный

Early Stopping на Validation

	Cat Boost	Light GBM	XGBoost
кодексы	Нормальная отработка (cat-features)	Native, но нужно уметь	арджен encoding функции
скорость	быстро	быстро	быстро
Рост сервера	Symmetric	Leaf-wise	Level-wise
Когда выбирать	Когда нужно быстро	Больше данных, нужна скорость	Универсал

Метрики

Классификация

Accuracy

$$\frac{TP + TN}{TP + TN + FP + FN}$$

Сбалансированность
классов

Precision

$$\frac{TP}{TP + FP}$$

Полнота срабатывания
горюч (сигнал)

Recall

$$\frac{TP}{TP + FN}$$

Полнота охвата
(охват, охват)

F1

$$2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Баланс
P и R, классы
не сбалансированы.

ROC-AUC

Площадь под ROC-кривой

Ранжирование,
вероятности
баллов

Confusion Matrix

	Pred Positive	Pred Negative
Actual Pos.	TP	FN
Actual neg	FP	TN

Результ

измеряет и прогнозирует

MSE

$$\frac{1}{n} \sum_{i=1}^n |y - \hat{y}|$$

✓ средняя абсолютная ошибка

MSE

$$\frac{1}{n} \sum_{i=1}^n (y - \hat{y})^2$$

среднеквадратичная ошибка и прогнозирует

$$RMSE = \sqrt{MSE}$$

R^2 - коэффициент детерминации

Важность признаков $\rightarrow$ MSE / RMSE

Подобрав признаки $\rightarrow$ MAE

Сравнить модели $\rightarrow$ RMSE или R^2

Объем выборки — MAE